



TECHNICAL REPORT · ARCHITECTURE · TRAINING · ASCEND SYSTEMS · PROVENANCE

openPangu 2.0

架构、训练与 昇腾系统全景 解读

从 MLA、DSA – SWA、PAS 与 ModAttn，到 mHC、Muon、MoE 系统协同、多专家 OPD 和昇腾推理栈：沿报告脉络重建 openPangu 2.0 的完整技术路线。

openPangu Team · 2026-07-30 · 中文技术报告解读 · 论文原图与官方配置交叉核对

505B / 18B Pro 主干总参数 / 每 token 激活参数	92B / 6B Flash 主干总参数 / 每 token 激活参数	34.4T 报告披露的分阶段训练 token 合计	512K 训练与公开配置的最大上下文长度
---	---	-------------------------------------	--------------------------------

00 · Executive reading核心判断：贡献重心在“组合、迁移与 腾落地”

openPangu 2.0 并未把主要贡献包装成一种全新的 Transformer 主干。它把 MLA、DSA、SWA、MoE、mHC、MTP、Muon 等已有路线组合为面向 512K 上下文与 Agent 工作负载的模型，再围绕 Ascend NPU 重做长序列训练、MoE 通信、算子融合、量化、缓存和异步调度。模型创新与系统工程必须放在一起解读。

ARCHITECTURE 全局检索 + 局部窗口 主体按 DSA – SWA – SWA 重复；PAS 提供可学习 attention sink，ModAttn 用短程因果卷积补充局部归纳偏置。	TRAINING 34T 级课程 + 后置稀疏化 从 4K 逐步扩到 512K，先训练 FULL – SWA，再用 108B replay 将 FULL 层转换成 DSA。
POST-TRAINING 四类 RL 专家 + OPD Reasoning、General、Agent、Coding 专家并行优化，最终通过多教师 on-policy distillation 融合到统一模型。	INFERENCE Ascend 全栈共设计 Felix CP、W8A8、融合算子、多流、Omni Cache、vLLM V1 异步调度与 MTP full graph 共同支撑部署。

一句话总结 openPangu 2.0 最具辨识度的成果，是把稀疏长上下文模型完整落到昇腾训练与推理系统上；最薄弱的披露则是训练卡数与时长、后训练数据量、主模型模块级消融，以及与外部模型或系统的严格同条件对比。

证据等级

明确采用技术报告直接写明 built upon、adopt、following，或官方配置可直接确认。	再设计上游技术明确，但 openPangu 对结构、训练流程或系统实现做了实质改造。
可比较解决相近问题或结构相似，但报告没有确认来源关系。	分析推断由参数、公式或系统约束推得，与作者直接结论分开。

01 · Model positioning两款主模型、端侧分支、checkpoint 口径与许可证

Relative positioning · 本文概括

openPangu-2.0-Flash

46 层主干、2 层 Dense + 44 层 MoE；256 个 routed experts，Top-8；面向低延迟和较小部署规模。

Relative positioning · 本文概括

openPangu-2.0-Pro

50 层主干、3 层 Dense + 47 层 MoE；384 个 routed experts，Top-8；面向更强推理与 Agent 能力。

结构参数	Flash	Pro
论文口径总参数 / 激活参数	92B / 6B	505B / 18B
Hugging Face 完整 checkpoint 自动统计	100B	541B
主干层 / Dense / MoE	46 / 2 / 44	50 / 3 / 47
hidden size / attention heads	2,560 / 48	5,120 / 64
MLA Q rank / KV rank	1,024 / 512	1,536 / 512
QK NoPE / RoPE dim; V head dim	128 / 64; 128	128 / 64; 128
Dense FFN intermediate	9,216	16,128
routed / shared experts	256 / 1	384 / 1
每 token routed Top-k	8	8
单 expert intermediate	1,024	1,792
DSA indexer heads / head dim / Top-k	24 / 128 / 2,048	32 / 128 / 2,048
DSA:SWA / SWA window	1:2 / 512	1:2 / 512
PAS / mHC streams / Sinkhorn	128 / 4 / 20	128 / 4 / 20
最终 MTP layers	3	3
原生上下文 / 最终 RoPE theta	512K / 6.4M	512K / 6.4M
架构词表大小	151,552	151,552

92B/505B 与 100B/541B 都没有写错 论文和模型卡使用主干模型口径；Hugging Face 对完整发布 checkpoint 的自动统计还包含 3 层 MTP 辅助层。权重索引中 Flash 为 46+3 层，Pro 为 50+3 层，因此差额很可能主要来自 MTP，但官方没有专门解释两个统计口径。

Pro model card Pro config Flash model card Flash config

许可证不是 Apache-2.0 模型权重采用 OpenPangu Model License Agreement 2.0，包含欧盟地域限制、再分发通知、“Powered by openPangu”展示要求及诉讼终止条款；推理源码仓库另以 Apache-2.0 发布。因而可以说“模型权重开放下载”，但不宜把整套权重与代码笼统描述为 Apache-2.0 开源。


1.3 报告还列出一款 30B / 2B active 端侧模型

这款 MoE 分支面向资源受限设备，并围绕 Kirin 硬件做量化、剪枝、专家复用与预取。它不是 Pro/Flash 的简单缩小版：系统瓶颈从数据中心的跨卡通信，转成设备内存容量、expert 频繁换入换出和加载停顿。


SCALE 30B / 2B active 报告只披露总参数与激活参数，没有层数、专家数或上下文配置。	KIRIN-AWARE 量化 + 剪枝 作者报告推理速度提高 50%、内存占用降低 20%。
EXPERT REUSE 相邻 token 复用专家 专门的 reuse loss 使 expert switching frequency 降低 50%。	PREDICTION 预测并预取专家 提前加载后续 token 可能选择的专家，作者报告吞吐最高提高 5×。

这些是作者报告的端侧收益，不是可独立复现的完整 benchmark 报告没有公开具体 Kirin 型号、精度口径、baseline、输入输出长度、并发、功耗、量化位宽或端侧 checkpoint；因此只能保留“作者报告”限定，不能把 50%、20%、5× 外推到任意设备。

02 · Architecture overview主干数据流：四路残差流包住混合注意力与 MoE



原报告 Figure 1, p.3。主体采用 DSA – SWA – SWA 注意力循环；Flash 前 2 层、Pro 前 3 层为 Dense FFN，其余为 MoE；四路 mHC 残差流贯穿主干，尾部附加 3 层 MTP。



架构的四层含义

ATTENTION RANGE 全局与局部职责分离 约三分之一层承担 DSA 全局检索，其余层只维护 512-token 窗口，降低 indexer、cache scan 与长序列通信的平均成本。	RESIDUAL TOPOLOGY 信息在四条流之间动态混合 mHC 不只是增宽 hidden size；它在残差状态层面保留四路表示，再通过约束矩阵读取、写回和混合。
CONDITIONAL COMPUTE 绝大多数层采用 MoE 每个 token 只激活 8 个 routed experts 与 1 个 shared expert，以激活参数显著小于总参数的方式扩展容量。	SELF SPECULATION MTP 既是训练目标也是推理草稿器 训练后期使用 3 个 MTP 层，一次额外预测三个位置；推理系统进一步为 MTP-3 做 full-graph 和异步调度。

03 · Hybrid attentionMLA + DSA – SWA：让少数层找远处，多数层看近处

openPangu 的注意力底座明确建立在 **Multi-head Latent Attention (MLA)** 上：Q 与 KV 先压缩到低秩 latent，再上投影为多头注意力需要的表示。这里不能把 **num_attention_heads** 误读成普通 GQA 的 Q-head/KV-head 数量；KV 的压缩由 latent rank 表达。

3.1 SWA：512-token 的局部工作马

Sliding-Window Attention 对真实历史 token 只读取最近 512 个，同时仍可访问固定的 128 对 PAS，负责局部语法、短程实体关系与连续状态更新。对单个 decode query，真实 token 的 cache read 和 attention compute 不随历史长度增长；但处理整段长度为 **S** 的 prefill 仍需 $O(S \cdot 512) = O(S)$ 的总工作量。

3.2 DSA：Lightning Indexer 先选 2,048 个历史 token

DSA 先用轻量 indexer 为历史 token 打分，再从因果可见历史中选 Top-k，随后只对这些 token 做稀疏注意力。论文正文使用“例如 $K=2,048$ ”的措辞，而官方 Pro/Flash 配置均确认 **index_topk=2048**；因此该值可作为发布 checkpoint 的实际配置，而不是仅凭论文例子推断。


LI score $\rightarrow$ causal TopK_{2,048} $\rightarrow$ sparse MLA attention

3.3 为什么不是每层都用 DSA

长上下文主导项	纯 DSA	FULL – SWA	DSA – SWA
Prefill 二次项系数	每层都跑 indexer	约 1/3 层 full attention	约 1/3 层跑 indexer
Decode cache read 线性项	每层读 indexer cache	约 1/3 层读 full KV	约 1/3 层读 indexer cache
Cache memory 线性项	KV + indexer	约 1/3 full KV	约 1/3 (KV + indexer)
局局部成本	仍需全局选择	SWA 固定窗口	SWA 固定窗口

关键不是“稀疏注意力天然便宜”，而是 DSA 的 indexer 自身仍随历史长度工作。把 DSA 只放到周期性全局层，可以把全局检索成本摊薄到约三分之一层。

3.4 后置稀疏化：先学好 FULL，再迁移到 DSA



只有原 FULL 层被替换成 DSA，SWA 层保持不变；Lightning Indexer 通过权重 0.1 的辅助目标拟合原 full-attention score。作者称 100B adaptation 后“mostly recovers”下游性能，但未提供 92B/505B 主模型的完整恢复曲线，因此不应写成无损迁移已经被充分证明。

04 · Local inductive biasPAS 与 ModAttn：为混合注意力补上“无处可看”和短程顺序

4.1 PAS：把 attention sink 显式参数化

每层增加 128 对可训练 latent K/V。它们不代表真实 token，而是为注意力提供稳定的“空操作”出口：当某个 query 没有值得关注的内容时，模型可以把 attention mass 分配给 PAS，而不是迫使序列开头或窗口内某个真实 token 充当 sink。

消融边界 PAS 的主要曲线来自 MoE15B-A2B，而非 92B/505B 主模型；对纯 full-attention baseline，PAS 没有显示明显 loss 收益。它的价值与混合 SWA 场景密切相关。

4.2 ModAttn：在压缩分支和注意力输出上做深度因果卷积

$$\text{Mod}_{\text{theta}}(Z) = Z + \text{CausalConv1D}_{\text{theta}}(Z)$$

该模块分别用于 MLA 的 compressed-Q 分支、compressed-KV 分支，以及 FlashAttention 聚合后、output projection 前。卷积为 depthwise causal Conv1D，**groups=H**、**kernel=3**，只引入极短程状态，却能为 DSA 的远程稀疏检索和 SWA 的固定窗口补充稳定的相邻 token 归纳偏置。




Figure 4, p.13. Sequence/Context Parallel 下只交换跨 rank 卷积边界，避免恢复完整相邻分区；Vector 核上的 rolling-state kernel 使模块计算时间降低 79%。

与 Mamba 的关系 报告把缓存语义称为“Mamba-like”，并指出 cache 方案可推广到 Gated DeltaNet；这说明状态组织相近，不足以证明 ModAttn 直接来源于 Mamba 或线性注意力。更稳妥的说法是：ModAttn 是报告定义的短程因果卷积组件。

05 · Conditional capacity & topologyMoE 与 mHC：扩容量，同时约束四路残差传播

5.1 Shared + routed experts

除 Flash 开头 2 个、Pro 开头 3 个 Dense FFN 层外，主干其余层均为 MoE。每个 token 始终经过一个 shared expert，同时从 256/384 个 routed experts 中激活 8 个。该结构与 DeepSeekMoE 路线高度相近，但报告在 MoE 结构处没有足够明确的“继承 DeepSeekMoE”声明，因此技术谱系中应标为结构相近，而非确定直接来源。

5.2 自适应 auxiliary-loss-free bias

$$b_i \leftarrow b_i - \text{gamma} \cdot (F_i - Q_i) / \text{RMS}(F - Q)$$

$$\text{RMS}(F - Q) = \sqrt{(1 / N_r) \cdot \sum_j (F_j - Q_j)^2}$$

$Q_i = 1/N_r$ 是目标负载, F_i 是 global batch 中实际专家负载。相较原 sign update, RMS 归一化保留了过载幅度的相对大小。bias update LR 为 $1e-3$; 另有权重 $2e-4$ 的 EP-group auxiliary loss 和 $1e-6$ 的 router z-loss。这些稳定项只在 General 阶段启用。




Figure 11, p.41。两种方法的 LM loss 接近, 但 RMS-normalized update 得到更低的 batch-level MaxVio。

5.3 mHC: 四条残差流的读取、写回与受约束混合

$$x_bar = \text{RMSNorm}(h_bar)$$

$$[r_pre, r_post, r_res] = x_bar W_{mHC}$$

$$H_{pre} = \text{sigmoid}(r_{pre}); H_{post} = 2 \text{ sigmoid}(r_{post}); H_{res} = \text{Sinkhorn}(\text{reshape}(r_{res}, 4, 4))$$

H_{pre} 决定子层从哪几条流读; H_{post} 决定输出写回哪几条流; H_{res} 在残差路径上做跨流混合, 并经 20 轮 Sinkhorn-Knopp 投影到近似双随机矩阵集合。它的目的不是让 residual 任意放大, 而是提升表示多样性的同时控制深层传播。

5.4 openPangu 对原 mHC 的稳定性修正

- 1 在子层输出写回 H_{post} 之前加入 sandwich normalization;
- 1 第一层之后以及每隔五层, 对多流主干做 block-level post-normalization;
- 1 针对浅层 H_{pre}/H_{post} 同时趋近 0 的 gate collapse 做专门修复。

MoE15B-A2B, 1T tokens	MMLU	CEval	BigBench	MATH	MBPP+	平均
baseline	.765	.708	.591	.459	.532	.594
mHC	.799	.743	.622	.472	.553	.615

平均提高 0.021, 但这是 15B 代理模型的消融; 不能据此精确拆分 mHC 对 92B/505B 最终成绩的贡献。

06 · Prediction & optimizationMTP 与 Muon：训练目标、投机草稿器和矩阵正交化

6.1 三层 MTP 的阶段调度

$$L = L_{\text{main}} + \sum_{k=1..D} \text{lambda}_k L_{\text{MTP}}^{(k)}$$


阶段	上下文	MTP 层数	loss 权重
General	4K	1	0.3
Reasoning	8K	1	0.1
Annealing	32K / 128K / 512K	3	每层 0.1，合计 0.3

所有 MTP 内部注意力均为 window=2,048 的 SWA。训练后期逐步增加 MTP 深度，使最终 checkpoint 可作为三层 self-speculative drafter；但论文未披露主模型的接受率、每轮平均接受 token 数或 MTP 单独带来的吞吐收益。

6.2 Muon + AdamW 混合优化


MUON 二维及更高维矩阵 momentum 0.95、Nesterov；Newton – Schulz 固定 5 轮；update 乘 gamma=0.2。MLA Q/KV up-projection 按 attention head 分成四组再正交化。	ADAMW 向量与敏感参数 embedding、prediction head、PAS、RMSNORM、mHC gate coefficient 等使用 AdamW；beta=(0.9,0.95)，epsilon=1e-8。
---	---

论文称 Muon 只维护一阶 momentum，因此 optimizer state memory 相比 AdamW 减半。全局 weight decay 为 0.1，但 embedding 与 RMSNorm 不衰减。



不要把经验解释写成因果结论 图中只证明 openPangu-2.0-Pro 在该训练配置下没有出现 QK logit explosion，不能独立证明是某一个 normalization 模块造成的。

07 · Pre-training34T 级数据课程：4K → 8K → 32K → 128K → 512K



7.1 数据构成

公开类别包括网页、图书、PDF、多语言文本、代码仓库、STEM、行业数据、agentic tasks 和 synthetic data。数据工程同时使用规则过滤与模型评估，为文档打 quality、difficulty、topic、educational value 标签，并对含长尾知识但格式较差的文本做语义保留式重写。

论文没有给出各类别或语言比例、去重率、污染检查、合成数据占比、具体数据集名单和版权分布。因而“34T”主要是 token 处理规模，不等于可审计的唯一语料量。

7.2 学习率、batch 与长度课程

阶段	长度与 token	Flash	Pro	RoPE base
General	25T @ 4K	batch→36M; peak LR 3e-4	batch→64M; peak LR 2e-4	10K
Reasoning	8T @ 8K	LR 1e-4 → 3e-5; 增加 STEM 与代码	100K	
Annealing-1	800B @ 32K	LR 从 3e-5 开始继续 cosine	400K	
Annealing-2	400B @ 128K	长文档和复杂 Agent trajectory	1.6M	
Annealing-3	200B @ 512K	最终 LR 8e-6	6.4M	

三个论文内部口径需要保留 三阶段相加为 34.4T，而摘要写“roughly 34T”；General 段落的“500B warm-up + next 17T plateau + final 8T decay”按字面是 25.5T，与 25T 阶段总量不一致；Tokenizer Table 4 为 149,600，而架构与官方 config 为 151,552，差出的 1,952 个 token 未解释。

7.3 Tokenizer：牺牲少量压缩率，换取规则的数字表示

Tokenizer 由中文、英文、代码、行业文档和 188 种低资源语言的重平衡混合重新训练。报告比较两种数字预切分：3-digit 以三位数字为组，压缩率更好；single-digit 把连续阿拉伯数字逐位切分，数字模式更规则。最终采用 single-digit，以服务数值推理、多模态坐标和工具参数，代价是平均字符/token 从 3-digit 的 2.71 降到 2.59。

Tokenizer	Vocab	中文	英文	多语言	代码	行业	平均字符/token
openPangu-1.0	153,376	3.82	4.30	2.80	2.80	4.18	2.56

Tokenizer	Vocab	中文	英文	多语言	代码	行业	平均字符/token
2.0 · 3-digit	150,400	4.04	4.27	3.37	2.77	4.51	2.71
2.0 · single-digit (最终)	149,600	3.82	4.15	3.32	2.56	4.27	2.59

Table 4 的 tokenizer vocab 是 149,600，而模型架构表与公开 config 是 151,552；两者差 1,952，报告没有解释是否来自特殊 token、padding 或发布配置扩展。


7.4 训练算力没有披露

报告确认基于 Ascend NPU 训练，并按 CloudMatrix 384 supernode 拓扑做 TP/CP/EP 亲和分组；但没有给出实际 NPU 总数、使用多少个超节点、训练天数、NPU-hours、总 FLOPs、MFU、吞吐、成本或能耗。“CloudMatrix 384”是产品/拓扑名称，不能被解释为“使用了 384 张卡训练”。

08 · Training systems长上下文、Muon、MTP 与 ModAttn 的系统协同

8.1 512K Context Parallelism

FULL 阶段使用 Ulysses + KV CP 的 Hybrid CP；DSA 阶段默认 KV CP。对 SWA，系统把全局 AllGather 改成相邻 rank P2P，通信量由与序列长度相关的 $S \cdot B \cdot H$ 降到窗口相关的 $W \cdot B \cdot H$ 。对 FULL/D SA，只交换同一 packed sub-sequence 的因果历史 KV，并以 AllToAllV 替代 AllGather。



8.2 FA Rescale: 在没有原生 PAS kernel 时精确合并两次 attention

$$O(A+B) = O(A) \alpha_A + O(B) \alpha_B$$

$$\alpha_X = l_X \exp(m_X - m^*) / [l_A \exp(m_A - m^*) + l_B \exp(m_B - m^*)]$$

两次 FlashAttention 分别处理真实序列和 PAS，利用 softmax max/sum 统计在 FP32 中合并。数学上等价于一次全局 softmax，差异只来自最终 BF16 rounding；DSA 的 KL 辅助目标还能只观察不含 sink 的主序列统计。

8.3 HyperParallel Muon+

在 DDP bucket ZeRO 下，系统根据 bucket/参数边界选择 AllGather 或 AllToAllV，并把 DP 拆成 **DPouter** × **DPinner**：outer 做跨 hyperplane 对称 AllGather，inner 控制 AllToAllV 范围。bucket i 的通信与 bucket i-1 的 Newton – Schulz 正交化和参数更新重叠。




Figure 3, p.12。只有首个 bucket 的通信和最后一个 bucket 的计算无法遮蔽。报告说其两级通信思想参考了 DeepEP，但这不等于直接使用 DeepEP 框架。

8.4 mHC 与 MTP 的流水线优化

- 1 无 PP 时做 intra-layer recomputation；PP+VPP 时跨层递归恢复，仅保留必要 activation。
- 1 PP 边界只传 mHC-expanded backbone hidden state，而不额外发送三个 MTP auxiliary payload；MTP state 到目标 stage 后本地展开。
- 1 最终 3 层 MTP 由 4 条跨 stage stream 降到 1 条，相关 P2P 下降 75%。
- 1 MTP layers 分散到 PP/VPP stages；projection/loss 按 sequence chunk 即时 forward-backward。
- 1 相较 unbalanced MTP layout，作者报告训练吞吐提高约 20%。

8.5 ModAttn kernel

跨 rank 只交换卷积边界；反向时从 attention output 重建 padding，避免缓存 padded tensor；因果卷积从 Cube 改到 Vector 核，以 rolling state 把三个局部状态保存在寄存器中。作者报告该模块计算时间降低 79%，这是模块级 latency，不是端到端训练提速。

09 · Post-training512K SFT、四类 RL 专家与多教师 OPD

9.1 统一 SFT


SFT 上下文直接设为 512K，同时混合 thinking 与 non-thinking 数据。四类数据覆盖 Reasoning、General Chat、Coding 和 Long-Trajectory Agent；Agent 轨迹来自真实 HarmonyOS 与模拟 sandbox，错误步骤由环境反馈与 reward model 定位并在训练时 mask。

9.2 四个并行 GRPO 专家

REASONING RL 数学、科学与工具 LLM quality filter、标签平衡，并对 Jupyter/Python parse error 施加惩罚。	GENERAL RL 通用对话 指令遵循、事实、长上下文、多轮交互；规则 reward 与 generative reward model 结合。
AGENTIC RL 长轨迹环境 TITO、动态移除持续解出的样本、工具语法惩罚、环境外确定性验证，从 General RL checkpoint warm start。	CODE RL 真实执行反馈 gateway 捕获 prompt/completion/logprob，重建完整 trajectory；monitor agent 在线监控 reward hacking。

四类专家均采用 GRPO，且不使用 KL regularization。报告没有披露各专家的 episode/token 数、batch、训练步数、奖励权重、NPU 规模与时长。

9.3 Multi-expert On-Policy Distillation



优势不再来自独立 reward，而来自领域 expert 与当前 policy 对实际生成 token 的概率差。近零优势 token 被 mask，极端 ratio 被 clip；多个教师不同时常驻，而是在共享 NPU pool 上顺序加载、分组打分。当前 expert probability 来自 training-engine forward，不是 inference backend。

10 · Train infer consistency当前缓解方案与“Full Alignment”预览必须分开

10.1 当前 openPangu 2.0 使用的缓解

- 1 训练从 BF16 改为 FP16，并使用 dynamic loss scaling；
- 1 KPop 替代大部分 IcePop / 普通 rejection sampling；

- 1 根据 train – rollout PCC 使用更严格或更宽松的 token mask；
- 1 R3 记录 rollout 时实际使用的 MoE routing，在训练端重放；
- 1 Masked R3 只对训练/推理专家重合足够高的 token replay；Cached R3 为多轮 Agent 保存首次生成时的 route record。

10.2 三类 mismatch

A · DEFINITION 模型定义不同 训练与推理侧算子、精度或状态定义不一致。	B · GRAPH 计算图重排 融合、并行分块和归约顺序改变数值路径。
C · SCHEDULING 硬件 tiling 非确定性 SplitK、聚合顺序、batch/shape 变化带来数值漂移。	




Figure 13: Strict alignment between training forward and inference prefill.




Figure 13 – 14, p.43。Phase I 用 tensor hook 和统一 FlashAttention 逐层定位差异；Phase II 构造单步 decode 输入并修改 CANN SplitK、聚合顺序与 tiling，再重新编译验证。

这是未来版本的技术预览 Introduction 明确把 full-alignment solution 放在 later model iterations，正文标题也使用 Preview。它不能被写成 openPangu 2.0 当前全部训练与 rollout 已经实现 bit-level 全栈对齐。

11 · Ascend inference并行、量化、融合、多级缓存与异步调度

11.1 官方部署栈与两种拓扑

一手资料确认的路径是 Ascend 910C/A3 上的 **omni-infer**，结合 AscendC、CANN、HCCL、ACL Graph、**npugraph_ex**、**omni-npu**、**omni-ops**，并扩展 vLLM V1 的异步调度与混合 KV cache。

部署形态	Prefill	Decode	公开参考拓扑
Ultra-low latency	PD-mix; SWA 用 TP、MoE 用 EP、DSA 用 CP	SWA 保持 TP、MoE 保持 EP; DSA 用 redundant weights 切到 TP	A3 单节点 latency 测试
Low latency / high throughput	PD-disaggregated; prefill topology 与 ultra-low 的 prefill 完全相同	Attention DP + MoE EP	Flash 1P1D / 2 nodes; Pro 2P1D / 8 nodes

Pro 官方 2P1D **inventory** 横跨 8 台主机、每台暴露 NPU 0 – 15，即 128 个可见 device；这是从参考拓扑推得的可见设备数，不是理论最低硬件门槛。HF 模型仓库也未提供普通 Transformers 单机 quickstart，目前没有一手证据支持通用 GPU/vLLM/SGLang 即插即用。

11.2 W8A8：不是全模型 INT8

权重采用 static symmetric per-output-channel INT8，激活采用 dynamic per-token INT8。对 SmoothQuant 的输入/输出平滑指数分别做二维搜索，并对 up projection 的输入/输出 smoothing 交替优化。

量化为 INT8/INT8	保留 BF16/BF16	原因
MLA o_proj、q_b_proj	kv_b、q_a、kv_a	小矩阵收益有限或对残差/双向使用敏感
Dense MLP gate/up/down	Lightning Indexer 全部投影	TopK 前的微小误差可能改变离散选择
Routed expert gate/up/down	shared expert、router gate	共享路径和路由对误差更敏感
—	embedding、LM head、mHC	输出质量与残差累计

论文分析口径中 Pro 权重约从 1009GB 降到 517GB，1.95×；HF 完整 INT8 仓库约 551GB。两者分别是模型权重分析与发布包体积，不能混作同一口径。


Pro INT8 checkpoint w8a8_dynamic config HF storage metadata BF16 deployment README INT8 deployment README

11.3 融合算子、MoE 通信与 Graph

MHC 关键路径拆分 融合上一层 merge、RMSNORM 与 Hpre; Hpost/Hres 放低优先级侧流，Sinkhorn 可独立重叠。	SWA / PAS L1 micro-tile 无效 tile 在搬入 L0 前跳过，PAS 常驻 L1；作者报告 SWA operator 提升 30% – 40%。
MOE DISPATCH Non-BSP + token-centric AtomicAdd 顺序化减少 barrier；每 token 只读取和量化一次，再发送给 Top-k experts。	ACL GRAPH 静态编译 + Superkernel static compilation 改善 TPOT 1.2ms，Superkernel 再改善 2ms，合计约 3.2ms。


不同数字的分母并不相同：有 operator latency、dispatch latency、module time、TPOT 和端到端 latency，不能把 79%、40%、30%、20%、5% 直接相加。

11.4 Felix CP：不同注意力层使用不同并行



DSA 只交换本 rank query 需要的 KV cache; SWA 在低维 ModAttn 后再 AllGather，并把 attention output 用 All2All 转回 SP。论文声称这是首个支持 APC 的开源 Mamba-like SP 实现，该“first”应保留作者限定。

11.5 Omni Cache：DRAM 保存历史，HBM 只放当前 buffer



D2H scatter 与 H2D gather 和每层计算重叠。作者报告 native KV space 超过 $10\times$ 、APC hit rate $3\times$ 、prefill max-batch-tokens $4\times$ ，并可在单个 A3 node 上继续支持 512K; 但没有给绝对命中率、DRAM 带宽需求或传输无法完全隐藏时的退化曲线。

11.6 Hybrid page、异步调度与 Multi-MTP full graph

- 1 DSA、SWA/MLA、ModAttn/Mamba-like cache 使用异构页面，并用统一 padded physical page + `torch.as_strided` 视图管理。
- 1 扩展 vLLM Single BlockPool、MambaSpec、prefix-cache negotiation 和 hybrid KV manager。

- 1 sampling/draft token 走独立 async copy stream; CPU tiling 下放 AICPU; DP batch coordination 改为 AICPU 上的 HCCL ProcessGroup。
- 1 启用 MTP-3 后，即使某次执行仅包含 1 – 3 个 token，也强制进入 static full graph; draft/target 统一 shape，减少额外 DP 同步。

11.7 LoPT: 基于原文字符位置的无损并行 tokenization




Figure 15, p.45。长文本重叠切块、多进程 tokenization，再依据 token 对应的原字符起止位置合并；边界匹配失败时动态扩大 chunk。

作者报告与串行 tokenizer 100% 一致，16-core CPU 提速 3 – 5×，overlap overhead 低于 5%。这里讨论的是 tokenization 到 1M 的系统能力，不代表模型原生上下文从 512K 升级为 1M。

12 · Evaluation速度、能力与证据边界分别看

12.1 理论长上下文收益不是端到端加速

相对 full-attention MLA	Hybrid DSA – SWA 理论系数	含义
Prefill 二次 attention FLOPs	约 1/15	只比较二次主导项，包含约三分之一层运行 Lightning Indexer 的二次成本；不代表端到端提速，也未计 core sparse attention、KV gather、projection、通信和 batching
KV cache growth	约 40.7%	8-bit hybrid 对 16-bit full 理想口径约 20.4%
Decode length-dependent cache scan	约 7.4%	8-bit 对 16-bit 理想口径约 3.7%

12.2 Ascend 实测

Table 7: Low-latency throughput for openPangu-2.0.

Model	ISL + OSL	TPOT (ms)	Batch Size	TPS (tokens/s per NPU)
openPangu-2.0-Flash	8K+1K	16.2	48	2963
openPangu-2.0-Flash	128K+8K	13.0	24	1846
openPangu-2.0-Pro	8K+1K	23.2	40	1727
openPangu-2.0-Pro	128K+8K	18.1	24	1326

single-batch input sequence length of 128K, under real data and real workloads, the measured Flash model TTFT is 2.6 s and the Pro model TTFT is 3.0 s; see Figure 8.




Table 6 – 7 与 Figure 7 – 8, p.28 – 29。随着输入增长，per-NPU TPS 下降、TTFT 上升；图表同时给出 8K – 128K 的趋势。

模式	模型 / ISL+OSL	TPOT	并发或 batch 口径	TPS/NPU
Ultra-low, A3 单节点	Flash / 8K+1K	5.27ms	global concurrency=1	—
Ultra-low	Flash / 128K+1K	5.63ms	global concurrency=1	—
Ultra-low	Pro / 8K+1K	9.53ms	global concurrency=1	—

模式	模型 / ISL+OSL	TPOT	并发或 batch 口径	TPS/NPU
Ultra-low	Pro / 128K+1K	9.55ms	global concurrency=1	—
Throughput	Flash / 8K+1K	16.2ms	per-NPU batch=48	2,963
Throughput	Flash / 128K+8K	13.0ms	per-NPU batch=24	1,846
Throughput	Pro / 8K+1K	23.2ms	per-NPU batch=40	1,727
Throughput	Pro / 128K+8K	18.1ms	per-NPU batch=24	1,326

128K single-batch prefill: Flash 单 A3 node TTFT 2.6s, Pro 两个 A3 nodes TTFT 3.0s。报告没有给同硬件外部 baseline、功耗、成本、MTP 接受率或完整 E2E server utilization; TPS/NPU 也不等于集群总吞吐。

12.3 能力评测怎么读：以下只是 Table 5 的部分代表性结果

Benchmark	Flash non-thinking	Flash thinking	Pro non-thinking	Pro thinking
IFEval · PromptStrict	89.3	95.9	90.4	94.5
AIME 2026 · Avg@16	86.5	93.3	87.3	95.4
GPQA-Diamond · Avg@4	79.8	83.7	81.1	87.9
BrowseComp · Acc	—	57.0	—	65.7
LiveCodeBench V6 · Avg@3	50.9	85.1	74.5	85.7
SWE-bench Verified · Avg@3	57.6	63.1	66.8	68.5
GDPVVal · Acc	—	51.4	51.2	74.9

Table 5 统一使用 top-p=0.8、temperature=1.0, 但只比较 openPangu 自身四种模式，没有外部模型列；粗体表示四个 openPangu 变体中最好，不代表行业最优。Claw-Eval 只测非多模态 splits; BrowseComp 使用 discard-all 且最多 300 iterations ; SkillsBench、FeatBench、DeepCodeBench 使用 OpenCode, SWE-bench 使用 OpenHands; GDPVVal 数据与 rubric 公开，但运行的是内部评测 pipeline。Deep Research 和全栈 mini-app 还依赖内部 pipeline 或 showcase，复现性弱于标准公开 benchmark。

13 · Technical provenance哪些可以画实线，哪些只能做横向比较

前序技术	关系与证据	openPangu 2.0 中的形态
DeepSeek-V2 · MLA	——□ 明确继承或采用 报告明确 built upon	openPangu MLA base
DeepSeek-V3.2 · DSA Longformer · SWA	——□ 明确继承或采用 明确采用两类组件	Hybrid DSA – SWA 1:2 interleaving
Attention Sink literature	· · · · · □ 相关但非直接祖先 / 未确认 问题与现象基础；非结构祖先	PAS · 128 latent K/V
Hyper-Connections	——□ 明确继承或采用 明确演进	mHC
mHC	——□ 明确继承或采用 采用并做稳定化	openPangu stabilized mHC 4 streams + sandwich / block postnorm
Aux-loss-free MoE balancing	——□ 明确继承或采用 明确采用并修改更新式	RMS-normalized bias update
MTP · Gloeckle et al. DeepSeek-V3 practice	——□ 明确继承或采用 明确技术上游	stage-adaptive MTP-3
Muon	——□ 明确继承或采用 明确采用	HyperParallel Muon+
Muon is Scalable for LLM Training	· · · · · □ 相关但非直接祖先 / 未确认 相关规模化前作与稳定性观察	openPangu Muon stability discussion
GRPO	——□ 明确继承或采用 明确用于专家 RL	Reasoning / General / Agent / Coding experts
On-Policy Distillation / MiniLLM 及报告引用的后续 OPD 工作	——□ 明确继承或采用 报告明确引用的蒸馏上游	multi-expert OPD fusion
SmoothQuant	——□ 明确继承或采用 量化基线	2D exponent search W8A8
vLLM Hybrid KV / Single BlockPool / APC	——□ 明确继承或采用 明确扩展缓存管理	Pangu hybrid cache manager
vLLM V1 scheduler	——□ 明确继承或采用 明确适配	openPangu async scheduler
Mamba / Gated DeltaNet	· · · · · □ 相关但非直接祖先 / 未确认 缓存语义可类比，未确认算法来源	ModAttn state cache
DeepEP	——□ 明确继承或采用 明确借鉴两级通信设计；未确认使用 DeepEP 框架	HyperParallel Muon+
Mooncake / LMCache	· · · · · □ 相关但非直接祖先 / 未确认 同类外部系统；报告未提及或未确认采用	Omni Cache

技术点	前序工作	openPangu 2.0 的变化	证据等级
MLA	DeepSeek-V2	作为 DSA/SWA 的共同压缩注意力底座	报告明确建立在其上

技术点	前序工作	openPangu 2.0 的变化	证据等级
DSA	DeepSeek-V3.2	与 SWA 按 1:2 编排，后置稀疏化	明确采用 + 组合/迁移再设计
PAS	Attention Sink 研究	每层 128 对持久化 latent KV	现象来源明确；结构为本文方案
ModAttn	无明确直接祖先	MLA 压缩分支与输出上的 kernel-3 因果卷积	报告提出
MoE 主体	与 DeepSeekMoE 路线高度相近	shared + routed experts、Top-8	结构相近；直接来源未确认
MoE 路由平衡	Auxiliary-Loss-Free Balancing；RMS 归一化更新	RMS-normalized load-balance bias	路线明确
mHC	Hyper-Connections → mHC	sandwich norm + block postnorm	明确继承 + 稳定化改造
MTP	Better & Faster LLMs；DeepSeek-V3	1→3 层阶段调度与 MTP-3 系统优化	明确上游 + 本文配方
Muon	Muon；Muon is Scalable 为相关规模 化前作	head grouping、HyperParallel Muon+	Muon 明确采用；前作为相关观察
OPD	On-Policy Distillation、MiniLLM 及 报告引用的后续 OPD 实践	四领域专家、training-engine 概率、 多教师调度	报告引用 + 工程化
Felix CP	Ulysses / KV CP 背景	DSA CP、SWA TP、ModAttn SP 的逐 层编排	报告新系统方案
Omni Cache	vLLM Hybrid KV / APC	DRAM-centric KV 与统一异构 page	明确扩展 + 自身缓存体系

14 · Evidence boundaries报告没有回答什么

COMPUTE 训练账单缺失 没有实际 NPU 数、超节点数、训练天数、NPU-hours、FLOPs、成本、能耗、吞吐或 MFU。	DATA 数据构成不可审计 没有来源比例、去重率、污染检查、许可证构成、合成数据占比和后训练 token/episode 数。
ABLATION 主模型拆解不足 PAS、mHC 的消融明确来自 15B 代理模型；routing-bias 曲线未注明模型规模；三者均缺少 92B/505B 的完整独立拆解。	LONG CONTEXT 512K 原生训练不等于无损 缺少从短上下文到 512K 的专门 accuracy 曲线，也没有完整展示 DSA 转换的恢复程度。
POST-TRAINING RL 规模与预算不透明 没有各专家训练量、GRPO 超参、thinking 输出预算、工具成本和 MTP 接受率。	EVALUATION 没有外部同表对比 Table 5 只比较自身四种模式，内部 Deep Research 与 mini-app showcase 难以独立复现。
INFERENCE Ascend 特定口径 缺同硬件外部 baseline、功耗和成本；operator、dispatch、TPOT 与 E2E 改善不能直接相加。	RELEASE 部署与许可存在边界 官方验证路径是 omni-infer + Ascend；权重许可证有地域和再分发限制，并非通用 Apache-2.0。

总评 openPangu 2.0 的可信度最高之处是架构参数、预训练日程和昇腾推理系统的细节披露；最需要保留折扣的，是“各模块分别贡献了多少”、训练资源账单、后训练规模，以及性能相对于其他模型和其他硬件栈的可迁移性。

15 · Primary sources—一手资料与技术溯源链接

- 1 [openPangu-2.0: Towards Reliable and Efficient Agentic Reasoning](#)
- 2 [openPangu-2.0-Pro model card](#) · [config](#)
- 3 [openPangu-2.0-Flash model card](#) · [config](#)
- 4 [openPangu-2.0-Pro-Int8](#) · [w8a8_dynamic config](#) · [HF storage metadata](#)
- 5 [openPangu-2.0-Infer / omni-infer deployment](#) · [BF16 README](#) · [INT8 README](#)
- 6 [Pro 2P1D reference inventory](#)
- 7 [openPangu-2.0-Op](#) · [omni-ops](#) · [OmniInfer](#)
- 8 [OpenPangu Model License Agreement Version 2.0](#)
- 9 [Attention Is All You Need](#)
- 10 [DeepSeek-V2 / Multi-head Latent Attention](#)
- 11 [DeepSeek-V3.2 / DeepSeek Sparse Attention](#)
- 12 [Longformer / Sliding-Window Attention](#)
- 13 [StreamingLLM / Attention Sinks](#) · [When Attention Sink Emerges](#)
- 14 [DeepSeekMoE](#) · [Auxiliary-Loss-Free MoE Balancing](#)
- 15 [Hyper-Connections](#) · [mHC](#)
- 16 [CogView / Sandwich normalization](#)
- 17 [Better & Faster LLMs via Multi-token Prediction](#) · [DeepSeek-V3](#)
- 18 [Muon](#) · [Muon is Scalable for LLM Training](#)
- 19 [DeepSpeed-Ulysses](#) · [ZeRO](#) · [DeepEP](#)
- 20 [FlashAttention](#) · [FlashAttention-2](#)
- 21 [DeepSeekMath / GRPO](#) · [On-Policy Distillation of Language Models](#) · [MiniLLM](#)
- 22 [Rollout Routing Replay](#) · [IcePop](#)
- 23 [SmoothQuant](#) · [vLLM](#)
- 24 [LoPT](#)
- 25 [Mooncake](#) · [LMCache](#)（同类外部缓存系统对照；报告未提及或未确认采用）

[openPangu 2.0 Technical Report](#) · [Independent Chinese Analysis](#)
Source version: [openPangu Team, 2026-07-30](#) · [Generated 2026-07-31](#)